

EJERCICIO. IA EN LOCAL. OLLAMA EN KUBUNTU

Mayo-2026

Vamos a definir nuestra propia IA en LOCAL con OLLAMA EN LINUX (KUBUNTU)

1. Instalar Ollama (El "Motor")

Ollama es el servicio que descarga y ejecuta los modelos de lenguaje (LLMs) en tu hardware.

Actualizamos el Linux

```
$> sudo apt update
$> sudo apt upgrade -y
$> sudo apt install curl           (Si curl no está instalado)
$> curl -fsSL https://ollama.com/install.sh | sh
$> systemctl status ollama  ó $> sudo service ollama status
```

2. Descargar un Modelo

Antes de ejecutar, necesitas un modelo que "piense". Vamos a bajar el más equilibrado actualmente (Llama 3.2 o Qwen 3, según tu preferencia).

En la misma terminal, escribe:

```
$> ollama run llama3.2
```

- Esto descargará el modelo (unos 2GB-5GB).
- Una vez termine, podrás chatear directamente en la terminal.
- **Explora modelos:** Puedes ir a la biblioteca de Ollama y probar otros modelos como mistral, deepseek-coder (para programar) o phi3 (muy ligero para PCs modestas).

Comandos esenciales de uso

Aprender estos comandos te permitirá gestionar tus modelos con total libertad:

- **/bye**: Salir del chat actual.
- **ollama list**: Ver todos los modelos que tienes descargados en tu Kubuntu.
- **ollama pull [nombre]**: Descargar un modelo nuevo sin ejecutarlo todavía (ej: ollama pull deepseek-r1).
- **ollama rm [nombre]**: Borrar un modelo para liberar espacio en disco.
- **ollama ps**: Ver qué modelo está cargado actualmente en tu memoria RAM/GPU.

LISTO! Ya puedes usar OLLAMA en el terminal

1. Multimodalidad (Visión de Imágenes)

Ollama soporta modelos multimodales que te permiten "subir" imágenes para que la IA las analice.

- **Qué puedes hacer:** Adjuntar fotos, capturas de pantalla o diagramas y preguntar: *"¿Qué dice este gráfico?", "Explícame este código de la captura" o "Describe esta imagen"*.
- **Modelos recomendados:** * llama3.2 (en sus versiones Vision).
 - llama-v1.6 o el nuevo gemma3 (con soporte nativo de visión).
 - moondream (muy ligero, ideal si no tienes mucha potencia).

2. Generación de Imágenes (Integración)

Aunque Ollama por sí mismo no genera imágenes (es un motor de lenguaje)

Si instalas PODMAN

Usar **Podman** es una alternativa excelente si buscas una gestión de contenedores que no dependa de un demonio central y que sea, por defecto, *rootless* (más segura).

Podman es mayoritariamente compatible con la sintaxis de Docker.

Los pasos para hacerlo con Podman:

1. Preparar Ollama

Asegúrate de que Ollama esté corriendo en tu máquina "host" (fuera de Podman).

- Si lo instalaste como aplicación nativa en Windows o macOS, simplemente ábrelo.
- **Importante:** Por defecto, Ollama solo escucha peticiones desde localhost. Para que el contenedor de Podman pueda hablar con él, debes configurar la variable de entorno OLLAMA_HOST a 0.0.0.0.

2. Ejecutar Open WebUI con Podman

En tu terminal, usa el siguiente comando. He ajustado la comunicación para que sea compatible con el modo en que Podman gestiona el tráfico hacia el host:

Bash

```
podman run -d \
```

```
-p 3000:8080 \
```

```
--name open-webui \  
--add-host=host.containers.internal:host-gateway \  
-e OLLAMA_BASE_URL=http://host.containers.internal:11434 \  
-v open-webui-data:/app/backend/data \  
--restart always \  
ghcr.io/open-webui/open-webui:main
```

¿Qué ha cambiado aquí?

- **host.containers.internal:** Es el equivalente en Podman al `host.docker.internal` de Docker. Permite que el contenedor salga a buscar a Ollama en tu máquina real.
- **-e OLLAMA_BASE_URL:** Le decimos explícitamente a la interfaz dónde está el "cerebro" (Ollama).
- **Volumen:** Podman creará un volumen llamado `open-webui-data` automáticamente para persistir tus datos.

3. Consideración de Seguridad (SELinux)

Si estás en una distribución tipo **Fedora, RHEL o CentOS**, SELinux podría bloquear el acceso al volumen. Si notas que el contenedor no arranca o da errores de permisos, añade `:Z` al final del volumen: `-v open-webui-data:/app/backend/data:Z`

4. Verificación

Una vez ejecutado, espera unos segundos y comprueba que el contenedor esté arriba:

Bash

```
podman ps
```

Luego, entra en `http://localhost:3000`. Si al intentar elegir un modelo no aparece nada, asegúrate de que el firewall de tu sistema no esté bloqueando el puerto 11434, que es por donde Ollama recibe las órdenes.

Ventaja adicional de Podman

Si usas **Podman Desktop**, puedes gestionar este contenedor desde una interfaz gráfica muy intuitiva, similar a Docker Desktop pero sin las restricciones de licencia para empresas que este último tiene.

2. Preparar Podman en Kubuntu

Kubuntu 24.04 tiene Podman en sus repositorios oficiales. Instalémoslo junto con las herramientas necesarias para que los contenedores se comuniquen bien:

Bash

```
sudo apt update
```

```
sudo apt install -p podman podman-docker uidmap
```

3. Configurar Ollama para conexiones externas

Por defecto, Ollama en Linux escucha solo en 127.0.0.1. Para que el contenedor de Podman pueda hablar con él, debemos abrirlo un poco:

1. Edita el servicio de Ollama:

Bash

```
sudo systemctl edit ollama.service
```

2. Se abrirá un archivo vacío (o con comentarios). Pega esto debajo de [Service]:

Ini, TOML

[Service]

Environment="OLLAMA_HOST=0.0.0.0"

Environment="OLLAMA_ORIGINS=*"

3. Guarda (Ctrl+O, Enter) y cierra (Ctrl+X).
4. Reinicia el servicio para aplicar los cambios:

Bash

```
sudo systemctl daemon-reload
```

```
sudo systemctl restart ollama
```

4. Lanzar Open WebUI con Podman

Ahora ejecutamos el contenedor. Usaremos el flag --network=host para simplificar la vida en Kubuntu, ya que permite que el contenedor comparta la red con tu sistema y vea a Ollama instantáneamente en localhost:11434.

Bash

```
podman run -d \
```

```
--network=host \  
-v open-webui:/app/backend/data \  
-e OLLAMA_BASE_URL=http://127.0.0.1:11434 \  
--name open-webui \  
--restart always \  
ghcr.io/open-webui/open-webui:main
```

5. Soporte para GPU (NVIDIA) en Kubuntu

Si tienes una tarjeta NVIDIA, querrás que la IA vuele. En Kubuntu 24.04 necesitas el "NVIDIA Container Toolkit" para que Podman pueda usar la tarjeta:

1. **Instala los drivers** (si no lo has hecho): `sudo ubuntu-drivers install` y reinicia.
2. **Instala el toolkit:**

Bash

```
sudo apt install -y nvidia-container-toolkit
```

3. **Configura Podman:**

Bash

```
sudo nvidia-ctk cdi generate --output=/etc/cdi/nvidia.yaml
```

4. **Ejecuta el contenedor con GPU:** Añade el flag `--device nvidia.com/gpu=all` al comando de `podman run` del paso anterior.

Bonus: ¿Prefieres Interfaz Gráfica?

Como estás en KDE (Kubuntu), puedes instalar **Podman Desktop**. Es una aplicación nativa que te permitirá ver los logs, detener o actualizar Open WebUI sin tocar la terminal. Está disponible como **Flatpak** en la tienda **Discover**.

¡Ya puedes entrar en `http://localhost:8080` (o el puerto que hayas definido) y empezar a descargar modelos! ¿Qué procesador y cuánta RAM tiene esa máquina? Ayuda mucho para saber qué modelos te irán más finos.