PILDORAS. FILTRACION DE DATOS EN ANTHROPIC

09/04/2026

Anthropic filtró por error sus secretos más valiosos — y lo que salió a la luz es inquietante

Una semana. Dos filtraciones masivas. Y preguntas que toda la industria de la IA debería estar haciéndose.

¿Qué ha pasado?

Entre el **26 y el 31 de marzo de 2026**, Anthropic —la empresa creadora de Claude y considerada por muchos como el referente ético del sector de la inteligencia artificial— protagonizó no uno, sino **dos incidentes de filtración de información interna** con apenas días de diferencia.

No fue un hackeo. No fue un ataque externo. Fueron **errores humanos internos**. Y eso, precisamente, lo hace más preocupante.

Filtración #1 — "Claude Mythos" / Proyecto Capybara (26 de marzo)

El miércoles 26 de marzo, dos investigadores de seguridad —uno de **LayerX Security** y otro de la **Universidad de Cambridge**— descubrieron que Anthropic tenía cerca de **3.000 archivos internos expuestos públicamente** en una base de datos sin protección.

Entre esos archivos apareció algo inesperado: un **borrador de publicación de blog** que describía un nuevo modelo de IA todavía no anunciado, conocido internamente como **"Claude Mythos"** (también referenciado como "Capybara").

¿Qué reveló ese documento?

- Que el nuevo modelo superaría en capacidad a todos los existentes de Anthropic.
- Que según los propios documentos filtrados, el sistema tendría una **capacidad avanzada para identificar y explotar vulnerabilidades de software**, algo que los propios ingenieros describían como un posible riesgo serio de ciberseguridad.
- Que el modelo ya habría sido utilizado en **ciberataques coordinados contra cerca de 30 organizaciones**.

El impacto fue inmediato: el ETF tecnológico iShares IGV cayó cerca de un 3%, y el precio de Bitcoin retrocedió desde los 70.000 a los 66.000 dólares en cuestión de horas tras conocerse la noticia.

Filtración #2 — El código fuente de Claude Code (31 de marzo)

Cinco días después, el lunes **31 de marzo**, se produjo un segundo golpe.

Al publicar una actualización del paquete @anthropic-ai/claude-code en **npm** (la plataforma que usan millones de desarrolladores para instalar herramientas de software), Anthropic subió por error un archivo interno de depuración (un *source map* de 59,8 MB) que permitió reconstruir prácticamente todo el código fuente de la herramienta.

Los números del desastre:

Dato	Cifra
Líneas de código expuestas	~512.000
Archivos afectados	~1.900
Ventana de exposición	00:21 – 03:29 UTC
Repositorios en GitHub con el código filtrado	+84.000 ⭐ en pocas horas

¿Qué reveló el código filtrado?

Investigadores de seguridad analizaron rápidamente el material y encontraron componentes que Anthropic nunca había descrito públicamente:

- **KAIROS**: un modo experimental de agente autónomo con ejecución proactiva de tareas.
- **Modo Encubierto**: una funcionalidad orientada a ocultar la participación de la IA en ciertos flujos de trabajo internos.
- **DiscoverSkills**: un sistema de exploración de capacidades internas basado en IA.
- Un sistema de **telemetría granular** que registra continuamente el comportamiento del usuario y puede sincronizarse con servidores externos.
- Un mecanismo de **feature flags remotos** que permite a Anthropic activar, desactivar o modificar funcionalidades del cliente sin que el usuario lo sepa.

Anthropic retiró rápidamente el paquete afectado, pero el daño ya era irreversible. El código circuló por internet y se distribuyó en múltiples forks. La empresa ha enviado solicitudes DMCA para intentar eliminarlo, con éxito muy limitado.

¿Qué dijo Anthropic?

La compañía confirmó que se trató de un **fallo en sus procesos internos**, no de un ataque malicioso. Respecto a la segunda filtración, afirmó que:

"No se involucraron ni expusieron datos o credenciales confidenciales del cliente."

Lo que sí quedó expuesto fue algo quizás más valioso a largo plazo: **la arquitectura interna, la hoja de ruta de producto y los mecanismos de control de una de las herramientas de IA más utilizadas del mundo**.

El contexto que lo hace aún más incómodo

Todo esto ocurre mientras Anthropic libraba simultáneamente una **batalla judicial contra el Departamento de Defensa de EE.UU.**, que había catalogado a la empresa como "riesgo para la cadena de suministro" tras negarse a permitir el uso de Claude sin restricciones para vigilancia y armamento autónomo. Un tribunal concedió una medida cautelar favorable a Anthropic **la misma semana de las filtraciones**.

La paradoja es evidente: la empresa que defiende principios éticos frente al Pentágono no fue capaz de proteger sus propios documentos internos de un simple descuido.

¿Qué implicaciones tiene todo esto?

Para Anthropic: La pérdida de propiedad intelectual es real. Competidores como Google, Meta o startups emergentes ahora tienen acceso a detalles sobre cómo está diseñado y optimizado Claude Code, lo que puede reducir su ventaja competitiva en un mercado muy disputado.

Para los desarrolladores: Los usuarios que instalaron o actualizaron Claude Code entre las 00:21 y las 03:29 UTC del 31 de marzo podrían haber descargado una versión comprometida. La recomendación es actualizar inmediatamente y rotar todas las claves secretas asociadas.

Para la industria: Esto no es solo un problema de Anthropic. Es un recordatorio de que **las empresas que construyen los sistemas más potentes del mundo no siempre tienen los controles más básicos en orden**. Y cuando dos fallos de esta naturaleza ocurren en la misma semana, dejan de parecer anécdotas para convertirse en señales de un problema estructural.

La pregunta que queda en el aire

Anthropic se ha posicionado siempre como la empresa de IA más responsable del sector. Su *soul document*, sus advertencias sobre riesgos existenciales, su rechazo al uso militar sin restricciones... todo apunta a una organización que se toma en serio las implicaciones de lo que construye.

¿Cómo se explica entonces que la misma empresa no tenga controles básicos para evitar que sus archivos internos acaben en internet?

Si no puedes proteger tu propio repositorio de npm, ¿cómo pretendes proteger un modelo que tú mismo describes como capaz de revolucionar los ciberataques?

¿Crees que este tipo de incidentes debería tener consecuencias regulatorias para las empresas de IA? ¿O seguimos confiando en la autorregulación del sector?

💬 *Me interesa tu opinión en los comentarios.*