

## PILDORAS. GOOGLE LANZA GEMMA 4

06/04/2026

### GUÍA DIDÁCTICA: IA LOCAL CON GEMMA 4

#### Tema: Modelos Eficientes y Descentralizados

#### 1. ¿Qué es Gemma 4?

Gemma 4 es la nueva familia de modelos de código abierto (licencia Apache 2.0) creada por Google DeepMind. A diferencia de otros sistemas que requieren superordenadores, Gemma 4 está diseñado para maximizar la inteligencia por parámetro.

"No se trata de ser el más grande, sino el más eficiente".

#### 2. Versiones y Hardware

Para que la IA sea accesible, existen diferentes "tallas" según el dispositivo donde se vaya a usar:

| Modelo      | Tamaño (Parámetros) | Uso recomendado                                                                 |
|-------------|---------------------|---------------------------------------------------------------------------------|
| E2B y E4B   | 2B - 4B             | Dispositivos ligeros: Móviles, Raspberry Pi, IoT.                               |
| 26B (MoE)   | 26B                 | Balance ideal: Muy rápido gracias a la arquitectura <i>Mixture of Experts</i> . |
| 31B (Dense) | 31B                 | Alta gama: Rendimiento profesional en portátiles potentes.                      |

*Nota: El modelo 31B compite en calidad con modelos hasta 20 veces más grandes.*

#### 3. Ventajas de la Eficiencia (IA Local)

El gran avance de Gemma 4 es permitir la Inferencia Local. Esto significa que la IA vive dentro de tu aparato, no en internet.

 Latencia casi nula: No hay que esperar a que los datos viajen a un servidor.

-  Privacidad: Tus conversaciones y datos personales nunca salen del dispositivo.
-  Coste cero: No necesitas pagar por el uso de APIs comerciales en la nube.
-  Sin conexión: Funciona perfectamente en lugares sin internet.

## 4. El Cambio de Paradigma

Estamos pasando de un mundo donde la IA era un servicio externo a un mundo donde la IA es una capacidad nativa del hardware.

IA en la Nube: Pasa a ser una capa "premium" solo para cálculos masivos.


IA Local: Se convierte en el estándar para el día a día (redacción, código, asistentes).

## 5. Actividad para el alumno

*Investiga qué es un modelo "Open Source" y explica por qué es importante que empresas como Google liberen el código de modelos como Gemma 4.*


## 6. Como instalar en tu móvil

Abrimos la tienda de aplicaciones de nuestro móvil



Te bajas Edge Galley e instalas EDGE GALLERY

Abres la aplicación



Seleccionas la IA que más se adapte a lo que necesitas. Puedes pedir información a Google, chatgpt, Gemini , etc.

Si queréis, vamos a probarlo sobre la marcha. Instaladlo las personas que podáis en vuestro dispositivo móvil. Los que no quieran o puedan ahora, que aprovechen estos minutos para leer el documento, o buscar información al respecto. Buscad las posibilidades de estas IA's en local.

## 7. Anexo

En el mundo de la Inteligencia Artificial, esa "**B**" es la unidad de medida fundamental para entender qué tan "inteligente" o complejo es un modelo. Significa **Billions** (mil millones, en inglés).

Cuando ves **4B** o **31B**, nos referimos al número de **parámetros** que tiene el modelo:

### 1. ¿Qué es un parámetro?

Imagina que el modelo de IA es un cerebro artificial compuesto por millones de conexiones. Los parámetros son como las **perillas o interruptores** que el modelo ajusta durante su entrenamiento para aprender conceptos, gramática o lógica.

- **Más parámetros** suelen significar más conocimiento y mejor razonamiento.
- **Menos parámetros** significan que el modelo es más ligero, rápido y consume menos memoria.

### 2. Diferencia entre 4B y 31B

| Característica | 4B (Pequeño/Edge)                                            | 31B (Grande/Dense)                                                |
|----------------|--------------------------------------------------------------|-------------------------------------------------------------------|
| Capacidad      | Entiende instrucciones básicas y redacta textos sencillos.   | Razonamiento complejo, programación y matices lógicos.            |
| Velocidad      | Instantánea.                                                 | Un poco más lenta (depende del hardware).                         |
| Hardware       | Puede correr en un <b>teléfono móvil</b> o una Raspberry Pi. | Necesita un <b>ordenador potente</b> (buena tarjeta gráfica/RAM). |
| Uso ideal      | Tareas rápidas, traducción simple, asistentes básicos.       | Análisis de datos, creación de código o redacción experta.        |